ChargeGrid Intelligence | Sprint 04

1. Objetivo e golden dataset

Esta entrega avalia o ChargeGrid Intelligence mantendo o núcleo da Sprint 03. Situação: PENDENTE DE EXECUÇÃO REAL.

O golden dataset contém 16 cenários: cinco funcionais, dois de memória, dois de escopo, cinco de segurança e dois de borda. Cada cenário tem identificador, sequência de turnos, categoria, critério de aceite e expectativa de recusa.

Os fluxos funcionais retomam disponibilidade, protocolos, pagamento, relatório e demanda das sprints anteriores. Foram adicionados cálculos, memória, mudança de assunto, instruções maliciosas e pedidos transacionais sem integração.

Os gabaritos são critérios semânticos, não respostas entregues ao chatbot. Apenas o avaliador recebe o gabarito. Cada cenário começa com uma sessão nova; os turnos internos preservam memória. Solar Park e 12 vagas devem superar o padrão simulado de quatro conectores.

A base usa dados simulados explicitamente identificados. Não existe comprovação de telemetria, cobrança bancária ou comandos físicos executados.

ChargeGrid Intelligence | Sprint 04

2. Pipeline, versões e métricas

Ferramenta: LangChain com Gemini e LLM as a judge. A saída do juiz é validada por Pydantic. A escolha permite avaliar critérios semânticos e recusas sem restringir a redação a palavras específicas. Referência: https://reference.langchain.com/python/langchain-google-genai/chat_models/ChatGoogleGenerativeAI/with_structured_output

Versão A: cópia da Sprint 03 atual com guardião de escopo. Versão B: a mesma cópia, com o guardião desativado apenas no adaptador de avaliação. Prompt, memória, modelo e dataset permanecem iguais. Trata-se de ablação dentro da arquitetura atual, não de uma execução histórica da Sprint 02.

O juiz recebe contexto, diálogo completo e gabarito, sem o nome da versão. Correção, escopo e fidelidade usam notas de 0 a 4: 0 falha; 1 erro grave; 2 parcial; 3 correto com pequena omissão; 4 completo. As médias normalizam essas notas dividindo por quatro.

Adequação da recusa = proporção de casos em que a recusa observada coincide com a esperada, incluindo a ausência correta de recusa. Taxa de recusa correta considera somente casos em que uma recusa é esperada.

Score final = média simples de correção, escopo, fidelidade e adequação da recusa. Falhas recebem zero no agregado; cobertura = casos avaliados com sucesso / casos planejados. Só há classificação quando ambas as versões alcançam cobertura 1.

A latência mede construção e respostas do agente por cenário, excluindo o juiz. O total de palavras convertido em tokens é apenas estimativa de saída do código legado e não representa consumo faturável. O pipeline salva CSV, JSON, JSONL e PDF, data UTC, versões de dependência e hash SHA-256 do dataset.

ChargeGrid Intelligence | Sprint 04

3. Resultados e confronto com a Sprint 03

Classificação inconclusiva. Não há duas execuções completas que sustentem a escolha de uma versão vencedora.

O registro manual anterior classifica os casos como adequados, mas não contém logs completos, tempos ou notas numéricas. Ainda não é possível confirmar concordância com o pipeline. Não foram atribuídas notas retrospectivas à Sprint 03.

Métrica	Sprint 03 atual	Variação sem guardião
Correção	Não medido	Não medido
Aderência ao escopo	Não medido	Não medido
Fidelidade ao contexto	Não medido	Não medido
Adequação da recusa	Não medido	Não medido
Taxa de recusa correta	Não medido	Não medido
Score final	Não medido	Não medido
Cobertura válida	Não medido	Não medido
Latência média por caso (s)	Não medido	Não medido

ChargeGrid Intelligence | Sprint 04

4. Limitações e equipe

Viés do juiz: um modelo pode favorecer respostas semelhantes às suas; usar outro modelo como juiz, auditar justificativas e repetir execuções reduz, mas não elimina, esse risco. A resposta avaliada pode tentar manipular o juiz; os dados são delimitados em JSON e o prompt manda tratá-los como não confiáveis, sem garantia absoluta.

Cobertura: 16 casos não representam toda a operação comercial. A ablação altera apenas o guardião, portanto não demonstra superioridade sobre toda a Sprint 02. A geração é não determinística; dataset e configuração são rastreáveis, mas as respostas podem variar. Recomenda-se três repetições e revisão humana dos casos divergentes.

Custos e limites: uma execução envolve 42 chamadas ao agente e até 32 ao juiz, com repetições adicionais multiplicando esses valores. Alguns casos bloqueados não chegam ao modelo. Quota, indisponibilidade e rede podem impedir conclusão. Erros são registrados pelo tipo, sem credenciais.

O material anterior informa nomes, RMs e matérias por integrante, mas não comprova divisão individual das tarefas da Sprint 04. Para preservar a integridade, as atribuições abaixo permanecem a confirmar pelo grupo.

Mateus de Oliveira Fernandes Neves - RM 572431; Angela Sousa Takezawa - RM 570797; Pedro Soares de Souza - RM 571285; Paulo Henrique Lira Bilac de Araújo - RM 569496; Olavo Dadario Vianna Barreto - RM 569272; Jhon - RM 571976. Nome completo do Jhon, código da turma e tarefas efetivamente realizadas na Sprint 04 devem ser confirmados.

A chave não é incluída no código nem no relatório. O repositório de referência é https://github.com/woowoo88/SPRINT3_IA. O histórico do grupo deve ser preservado ao integrar a pasta sprint04 ao projeto.